

Analisis comparativo de IA, Machine Learning, Data Mining y Big Data

Casos de estudio y aplicacion a la practica ETL

Alumno: Rayder

Repositorio de apoyo: <https://github.com/RayderHub/practica-airflow-postgresql>

1. Analisis comparativo

La inteligencia artificial, machine learning, data mining y big data se relacionan, pero no son lo mismo. La IA es el campo mas amplio; machine learning aprende de datos; data mining descubre patrones; y big data permite manejar informacion masiva o compleja.

Concepto	Caracteristicas	Beneficios	Retos	Aplicaciones	Herramientas
IA	Sistemas que simulan capacidades humanas como razonar o decidir.	Automatiza y mejora decisiones.	Datos, sesgos y explicabilidad.	Chatbots, fraude, recomendaciones.	Python, TensorFlow, PyTorch.
Machine learning	Modelos que aprenden patrones desde datos.	Predice y clasifica comportamientos.	Sobreajuste y calidad de variables.	Churn, ventas, spam.	Scikit-learn, XGBoost, Jupyter.
Data mining	Busca patrones y relaciones en datos historicos.	Convierte datos en conocimiento util.	Interpretar bien correlaciones.	Segmentacion, canasta de mercado.	SQL, Python, Weka, Power BI.
Big data	Procesa volumen, velocidad y variedad de datos.	Analisis masivo y casi en tiempo real.	Costo, infraestructura y gobierno de datos.	Logs, sensores, redes sociales.	Spark, Hadoop, Kafka, BigQuery.

2. Caso de estudio 1: Electro-Hogar S.A.

Objetivo y alcance

El objetivo es analizar el comportamiento historico de los clientes para identificar factores asociados al abandono, mejorar la retencion y aumentar el valor de vida del cliente. El alcance incluye ventas, clientes, productos, promociones, canales, ubicacion y servicio postventa.

- Identificar clientes que no realizan segunda compra.
- Segmentar por recencia, frecuencia y monto.
- Detectar variables relacionadas con abandono.
- Proponer acciones de retencion basadas en datos.

Metodologia

La metodologia recomendada es CRISP-DM, porque permite iniciar con el entendimiento del negocio y de los datos antes de pasar a modelos. Tambien se propone analisis RFM para clasificar clientes por recencia, frecuencia y valor monetario.

Etapas	Actividad
Negocio	Definir abandono e indicadores como recompra, ticket promedio y valor de vida.

Etapa	Actividad
Datos	Revisar fuentes, faltantes, duplicados y formatos.
Preparacion	Integrar ventas y clientes; crear variables utiles.
Exploracion	Comparar clientes retenidos y no retenidos.
Segmentacion	Aplicar RFM y clustering.
Modelado	Preparar variable objetivo y particion train/test.
Acciones	Proponer campanas, promociones y fidelizacion.

3. Caso de estudio 2: Practica ETL

El dataset usado corresponde a ventas de e-commerce. Aunque la instruccion menciona contrataciones, se adapta el analisis al contexto real de la practica ETL realizada con Airflow, PostgreSQL y Python.

Diagnostico inicial

- Filas crudas: 541,909.
- Clientes faltantes: 135,080.
- Descripciones faltantes: 1,454.
- Facturas canceladas: 9,288.
- Registros duplicados: 5,268.
- Cantidades negativas: 10,624.
- Precios unitarios menores o iguales a cero: 2,517.

Grano de la tabla de hechos

El grano seleccionado es una linea de producto dentro de una factura de venta. Este nivel conserva el detalle necesario para analizar ventas por producto, cliente, pais, fecha y factura.

Esquema de data warehouse

Tabla	Tipo	Contenido
fact_venta_linea	Hechos	fecha, cliente, producto, pais, factura, cantidad, precio, importe y variable objetivo.
dim_fecha	Dimension	Dia, mes, anio, trimestre y dia de semana.
dim_cliente	Dimension	Cliente original, segmento y bandera de cliente identificado.
dim_producto	Dimension	Codigo, descripcion limpia y categoria estimada.
dim_pais	Dimension	Pais limpio y region.
dim_factura	Dimension	Factura, tipo y cancelacion.

Limpieza y expresiones regulares

Objetivo	Regex	Uso
Limpiar descripciones	[^A-Z0-9\s\~]	Quita símbolos y caracteres corruptos.
Normalizar espacios	\s+	Convierte varios espacios en uno.
Validar facturas	^C?\d{6}\$	Acepta facturas y cancelaciones.
Variantes corporativas	\b(SA DE CV SAPI DE CV SRL SC AC)\b	Homologa proveedores si el dataset fuera de contrataciones.

Variable objetivo y particionamiento

Se creo la variable binaria alto_valor_transaccion. Vale 1 cuando el importe de la linea es igual o mayor a la mediana de importes positivos, y 0 cuando es menor. Se exportaron archivos balanceados para la fase de mineria de datos.

Archivo	Registros	Clase 0	Clase 1
train_ecommerce_balanced.csv	16,000	8,000	8,000
test_ecommerce_balanced.csv	4,000	2,000	2,000